Instituto Federal do Norte de Minas Gerais
campus Montes Claros
Curso de Bacharelado em Ciência da Computação

COLORAÇÃO ARTIFICIAL DE IMAGENS EM TONS DE CINZA

ENDI DANIEL COELHO SILVA
Orientador: Prof. Wagner Ferreira de Barros

Montes Claros
Fevereiro de 2018

ENDI DANIEL COELHO SILVA

COLORAÇÃO ARTIFICIAL DE IMAGENS EM TONS DE CINZA

Monografia apresentada ao Curso de Graduação em Ciência da Computação do Instituto Federal do Norte de Minas Gerais – Campus Montes Claros, como requisito parcial para a obtenção do grau de Bacharel em Ciência da Computação.

Orientador: Prof. Wagner Ferreira de Barros

Montes Claros

Fevereiro de 2018

© 2018, Endi Daniel Coelho Silva.
Todos os direitos reservados.

Coelho Silva, Endi Daniel
D1234p Coloração artificial de imagens em tons de cinza / Endi Daniel Coelho Silva. — Montes Claros, 2018
xvi, 44 f. : il. ; 29cm

Monografia (graduaÃğÃčo) — Instituto Federal do Norte de Minas Gerais
Orientador: Prof. Wagner Ferreira de Barros

1. Transferência de cores. 2. Processamento de Imagens. 3. Segmentação de Imagens. 4. Extração de características. I. TÃŋtulo.

CDU 519.6*82.10

[Folha de Aprovação]

Quando a secretaria do Curso fornecer esta folha,
ela deve ser digitalizada e armazenada no disco em formato gráfico.

Se você estiver usando o `pdflatex`,
armazene o arquivo preferencialmente em formato PNG
(o formato JPEG é pior neste caso).

Se você estiver usando o `latex` (não o `pdflatex`),
terá que converter o arquivo gráfico para o formato EPS.

Em seguida, acrescente a opção `approval={`*nome do arquivo*`}`
ao comando `\ppgccufmg`.

Resumo

O processo de colorir uma imagem manualmente é uma tarefa extremamente cara e demorada, pois cada pixel é tratado individualmente, além disso, para alcançar um bom nível de realismo é necessário buscar descrições da cena original que indiquem quais eram as cores originais da cena.

Com o objetivo de automatizar e facilitar este processo, neste trabalho foi desenvolvido um método semi-automático avançado, que realiza a coloração de imagens em tons de cinza, utilizando uma imagem colorida similar como referência, onde o método irá transferir automaticamente as características cromáticas da referência para a imagem em tons de cinza.

Ambas imagens são dividias em K regiões de acordo com a similaridade de seus pixels, em seguida é feito um mapeamento que vai indicar qual grupo da imagem colorida irá transferir suas cores para algum outro grupo da imagem em tons de cinza, feito o mapeamento, as características cromáticas da imagem referência são transferidas para a imagem em tons de cinza.

Ao final foi realizada uma comparação com outro método da literatura, em duas situações, a primeira, que pode ser descrita como a situação ideal, os dois métodos foram utilizados para realizar a coloração de imagens em tons de cinza, utilizando como referência sua versão original em cores, após isso, foi calculada a diferença absoluta pixel a pixel entre os resultados obtidos pela coloração gerada por ambos os métodos e as imagens referência originais, resultando no erro do processo de auto-coloração, comparando média e o desvio padrão do erro obtido nas imagens de teste, percebeu-se que o erro gerado pelo método proposto foi menor em todas as imagens.

Para a segunda situação utilizamos seis imagens em tons de cinza que foram coloridas por ambos os métodos utilizando imagens referência similares e os resultados da coloração foram disponibilizados para avaliação, através de um formulário, para usuários de uma rede social, onde o método desenvolvido neste trabalho foi melhor avaliado em quatro das seis imagens.

Palavras-chave: Similaridade, Pixel, Mapeamento.

Abstract

The process of coloring an image manually is an extremely expensive and time-consuming task because each pixel is treated individually, and to achieve a good level of realism, it is necessary to look for descriptions of the original scene that indicate the original colors of the scene.

In order to automate and facilitate this process, an advanced semi-automatic method was developed in this work, which performs the colorization of grayscale images using a similar color image as reference, where this reference image will automatically transfer its characteristics colors for the grayscale image.

Both images are divided into K regions according to the similarity of their pixels, then a mapping is done which will indicate which group of the color image will transfer its colors to some other group of the grayscale image, after th mapping, the chromatic characteristics of the reference image are transferred to the grayscale image.

At the end, a comparison was made with another method of the literature, in two situations, the first, which can be described as the ideal situation, the two methods were used to perform the coloration of grayscale images, using as reference their original version in color, after that, the absolute pixel-to-pixel difference was calculated between the results obtained by the coloration generated by both methods and the original reference images, resulting in the auto-coloration process error, comparing mean and standard deviation of the obtained error in the test images, it was noticed that the error generated by the proposed method was smaller in all the images.

For the second situation we used six grayscale images that were colored by both methods using similar reference images and the results of the coloration were made available for evaluation through a form for users of a social network, where the method developed in this work was best evaluated in four of the six images.

Keywords: Similarity, Pixel, Mapping.

Sumário

Resumo vii

Abstract ix

Lista de Figuras xiii

Lista de Tabelas xv

1 Introdução 1

1.1 Trabalho Anterior . . . 3
1.2 Definição do Problema . . . 4
1.3 Objetivo Geral . . . 5
1.3.1 Objetivos Específicos . . . 5
1.4 Organização do Trabalho . . . 6

2 Conceito Básicos 7

2.1 Redes Neurais Artificiais . . . 7
2.2 Imagens Digitais . . . 7
2.2.1 Representação de Imagens . . . 8
2.2.2 Imagens Monocromáticas . . . 8
2.3 Espaço de cores . . . 8
2.3.1 Espaço de cores RGB . . . 8
2.3.2 Espaço de cores L$\alpha\beta$. . . . 9
2.3.3 Espaço de cores HSV. . . . 10

3 Trabalhos Relacionados 11

3.1 Coloração Semi-Automática . . . 11
3.1.1 Coloração Semi-Automática Avançada . . . 12
3.2 Coloração Automática . . . 13
3.2.1 Busca em Banco de Dados . . . 13
3.2.2 Redes Neurais . . . 13

4 Metodologia **15**
4.1 Base de Imagens . . . 15
4.2 Imagens de Entrada . . . 15
4.3 Mudança de Espaço de Cores . . . 16
4.4 Extração de Características . . . 16
4.4.1 Variância e Desvio Padrão . . . 17
4.4.2 Entropia . . . 17
4.4.3 Local Binary Pattern . . . 18
4.4.4 Momentos estatísticos . . . 18
4.4.5 Máscara de Sobel para identificar bordas . . . 19
4.4.6 Melhor combinação de características . . . 19
4.4.7 Métricas de Similaridade . . . 20
4.5 Detecção do Número de Grupos . . . 21
4.5.1 Elbow Method (Método do Cotovelo) . . . 21
4.5.2 HSV (Hue, saturation, value) . . . 21
4.6 Normalização dos dados . . . 21
4.7 Agrupamento dos Pixels utilizando o K-Means . . . 23
4.8 Mapeamento dos grupos . . . 24
4.9 Transferência de Cores . . . 25

5 Resultados e Discussões **27**
5.1 Conjunto de Características . . . 27
5.2 Métricas de Similaridade . . . 28
5.3 Método Desenvolvido vs Welsh et al. . . . 29
5.3.1 Auto-Coloração . . . 30
5.3.2 Erros . . . 33
5.3.3 Transferência de Cores . . . 34

6 Conclusões **39**

Referências Bibliográficas **41**

Lista de Figuras

1.1 Albert Einstein, Verão de 1939 Nassau Point, Long Island, New York Que [2013]. . . . 1
1.2 Cena do filme Casablanca colorizado [Chris, 2008]. . . . 2
1.3 Exemplo do processo de transferência de cores por demarcações proposto por Reinhard et al. [2001]. A aparência da imagem em (b) é transferida para a imagem em (a) obtendo-se a imagem (c). . . . 3
1.4 Exemplo do processo de transferência de cores por demarcações proposto por Levin et al. [2004]. . . . 3
1.5 Coloração bem-sucedida 4
1.6 Coloração com falhas 4

2.1 Espaço de cores RGB Gonzalez & Woods [2001]. . . . 9
2.2 Espaço de cores $L\alpha\beta$ Blathur [2013]. . . . 10
2.3 Espaço de cores HSV MathWorks [2017]. . . . 10

3.1 Coloração automática Welsh et al. [2002] 12
3.2 Coloração utilizando demarcações Welsh et al. [2002] 12
3.3 Entrada, Imagem Colorizada pelo algoritmo, Imagem Original Zhang et al. [2016] 14

4.1 Esquema da metodologia utilizada 16
4.2 cálculo LBP Ojala et al. [1995] 18
4.3 Imagem referência e Imagem em tons de cinza 22
4.4 Comparação da segmentação das imagens, normalizadas e não normalizadas 22
4.5 Funcionamento do K-Means Towers [2013]. . . . 23
4.6 Imagem referência e imagem em tons de cinza 24
4.7 Segmentação da Imagem referência e da imagem em tons de cinza 24

5.1 Comparação entre conjuntos de características 28
5.2 Comparação entre métricas de similaridade 29

5.3 Comparação entre métricas de similaridade 29
5.4 Coloração bem-sucedida 30
5.5 Coloração bem-sucedida 30
5.6 Coloração bem-sucedida 31
5.7 Coloração bem-sucedida 31
5.8 Coloração bem-sucedida 32
5.9 Coloração bem-sucedida 32
5.10 Coloração bem-sucedida 35
5.11 Coloração bem-sucedida 36
5.12 Coloração bem-sucedida 36
5.13 Coloração bem-sucedida 37
5.14 Coloração com falhas 37
5.15 Coloração com falhas 38

Lista de Tabelas

4.1 Posição dos centroides da imagem colorida. 25
4.2 Posição dos centroides da imagem cinza. 25
4.3 Distância entre os centroides da imagem colorida em relação a imagem em tons de cinza. 25

5.1 Erros relacionados a Figura 5.4 33
5.2 Erros relacionados a Figura 5.5 33
5.3 Erros relacionados a Figura 5.6 33
5.4 Erros relacionados a Figura 5.7 34
5.5 Erros relacionados a Figura 5.8 34
5.6 Erros relacionados a Figura 5.9 34
5.7 Porcentagem de votos recebidos durante a avaliação subjetiva. 35

Capítulo 1

Introdução

Imagens coloridas geralmente são mais vivas e tem um apelo visual muito maior do que as imagens em tons de cinza, além disso a cor presente nas imagens pode facilitar a extração e detecção de informações. Logo, na década de 80 a coloração de imagens históricas e filmes antigos transformou completamente a indústria cinematográfica daquela época.

O processo de colorizar uma imagem manualmente é uma tarefa árdua, pois para alcançar um bom nível de realismo é necessário buscar descrições da cena original para que a cor das roupas, dos objetos, do cabelo, de todos os detalhes da imagem estejam próximos da realidade, veja como exemplo a Figura 1.1. Além disso, os *pixels* devem ser coloridos individualmente, o que torna essa tarefa bastante demorada e cara.



Figura 1.1. Albert Einstein, Verão de 1939 Nassau Point, Long Island, New York Que [2013].

Se colorizar imagens históricas já é uma tarefa complicada, colorizar filmes antigos é uma tarefa muito mais difícil, pois cada segundo de um filme normalmente tem 24 *frames*, ou seja, como cada segundo tem 24 imagens, em uma hora de um filme 86400 imagens teriam que ser colorizadas.

O processo de melhorar filmes monocromáticos através da adição de cor é amplamente atribuído a C. Wilson Markle cuja empresa Colorization Inc. lançou em agosto de 1985 o primeiro filme colorizado. A tecnologia utilizada nessa época era manual e, portanto, cara. Além disso, consumia bastante tempo, por exemplo, a colorização do filme Casablanca (Figura 1.2) em 1988 demorou mais de dois meses e custou aproximadamente 450000 dólares, em um processo que envolveu até mesmo uma pesquisa sobre as cores originais das roupas que foram utilizadas pelos atores e atrizes do filme [Vieira et al., 2003; Edgerton, 2000].



Figura 1.2. Cena do filme Casablanca colorizado [Chris, 2008].

Enquanto a colorização de imagens históricas e filmes clássicos são feitas com a intenção de aumentar o seu apelo visual, algumas outras técnicas de coloração são desenvolvidas especificamente com o objetivo de facilitar a visualização de imagens científicas, industriais e de segurança [Welsh et al., 2002; Gonzalez & Wintz., 1987].

Apesar de ser uma tarefa difícil de ser realizada manualmente, é possível automatizar a colorização de imagens tendo-se uma imagem colorida semelhante àquela imagem que se deseja colorir. Para realizar tal tarefa, pode-se classificar os algoritmos em duas categorias baseadas em abordagens globais ou locais [Arbelot et al., 2015].

Na abordagem global, é analisada uma característica global da imagem de referência de forma que esta se aproxime ao máximo da imagem originalmente em tons de cinza. Dessa forma, espera-se que, ao final do procedimento, a imagem alvo venha a apresentar a mesma característica cromática global da imagem de referência. Este método foi introduzido pela primeira vez em Reinhard et al. [2001], com o objetivo de transferir a

aparência de uma imagem pra outra, causando efeitos visuais muito interessantes, veja a Figura 1.3.

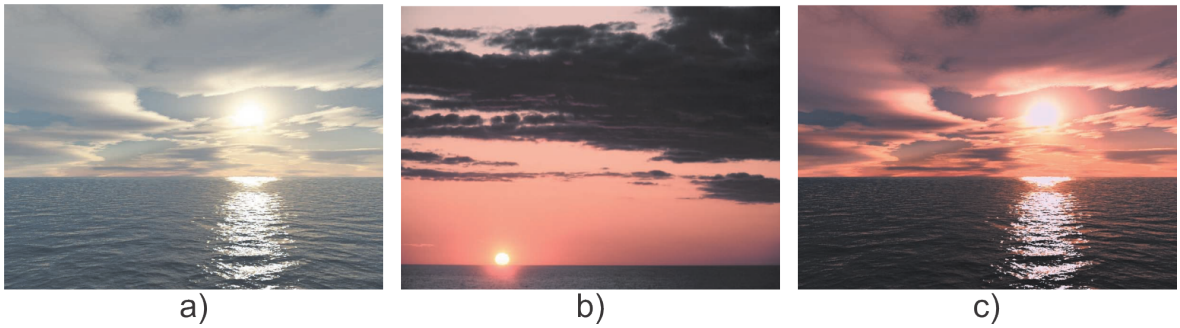


Figura 1.3. Exemplo do processo de transferência de cores por demarcações proposto por Reinhard et al. [2001]. A aparência da imagem em (b) é transferida para a imagem em (a) obtendo-se a imagem (c).

Em abordagens locais, as imagens geralmente são segmentadas em regiões para que posteriormente, as informações cromáticas de cada região da imagem de referência sejam adicionadas a cada região correspondente na imagem originalmente em tons de cinza. O processo de segmentação pode ser realizado de forma manual, como em [Levin et al., 2004], onde as regiões são marcadas manualmente com as informações cromáticas que devem ser atribuídas, (Figura 1.4), ou ainda, pode ser realizado por metodologias que segmentam e associam as cores nas imagens de forma automática [Vieira et al., 2007] ou semiautomática [Imran, 2011; Welsh et al., 2002; Levin et al., 2004].

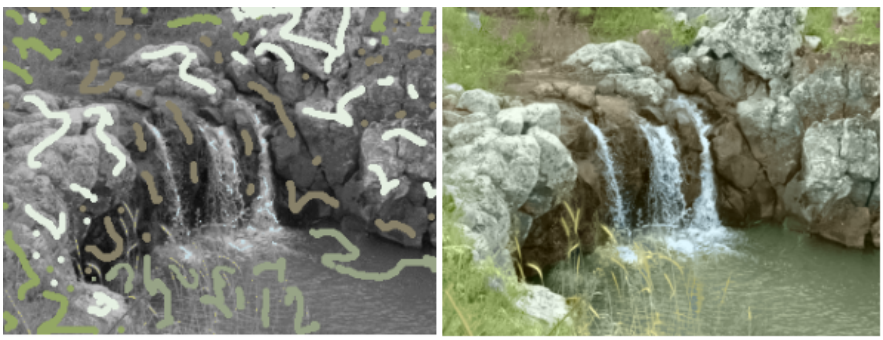


Figura 1.4. Exemplo do processo de transferência de cores por demarcações proposto por Levin et al. [2004].

1.1 Trabalho Anterior

Em 2016 foi realizado um trabalho multidisciplinar envolvendo as disciplinas de Inteligência Artificial e Computação Gráfica, onde foi feita uma simplificação no método

proposto por Imran [2011], como resultado, o trabalho desenvolvido foi publicado em Silva et al. [2016]. Diferente do método proposto por Imran [2011], apenas a luminância e a entropia foram utilizadas como vetores de características para alimentar o algoritmo de agrupamento *K-Means* e, dessa forma, o algoritmo alcançou bons resultados, porém apenas em cenas simples como na Figura 1.5, ou seja cenas onde os níveis de luminância presente em cada uma das regiões são bem distintos. No entanto o método ainda apresenta falhar em algumas situações como por exemplo :

- Imagens com o mesmo tipo de textura se repetindo entre as regiões.
- Regiões distintas com níveis de luminância bem paredicos.

A Figura 1.6 ilustra é um exemplo disso.



(a) Imagem referência (b) Imagem tons de cinza (c) Resultado

Figura 1.5. Coloração bem-sucedida



(a) Imagem referência (b) Imagem tons de cinza (c) Resultado

Figura 1.6. Coloração com falhas

1.2 Definição do Problema

Observa-se que ainda há como melhorar o processo de transferência cromática para obter melhores resultados com o método desenvolvido em Silva et al. [2016]. O problema a ser tratado neste novo trabalho consiste em: *"A partir de duas imagens, uma em tons de cinza e outra similar colorida, como transferir automaticamente as cores da imagem colorida para a imagem em tons de cinza de forma que o resultado final esteja próximo*

da realidade?". Dentre as diversas questões que surgem do problema a ser resolvido, pode-se enumerar as seguintes:

1. Quais características de ambas imagens devem ser utilizadas para segmentar as imagens em regiões?
2. Como definir automaticamente qual a quantidade de regiões em que as imagens serão divididas?
3. Qual método de segmentação de imagens, ou agrupamento de regiões, será utilizado?
4. Qual a melhor métrica para corresponder os grupos ou segmentos obtidos das imagens de entrada?
5. Como realizar o processo de transferência cromática dadas as regiões correspondentes entre as imagens?

1.3 Objetivo Geral

O objetivo geral deste trabalho é desenvolver um método que seja capaz de transferir as cores de uma imagem de referência para uma imagem em tons de cinza, de forma totalmente automatizada, ou seja, sem qualquer intervenção humana, afim de obter resultados realísticos, isso será feito realizando uma melhoria em cima do trabalho desenvolvido anteriormente. Logo, iremos buscar quais são as características que melhor descrevem as imagens, para então verificar como segmentar a imagem, para só então realizar a transferência cromática entre as imagens.

1.3.1 Objetivos Específicos

- Definir quais características descrevem melhor as imagens.
- Segmentar a imagem em tons de cinza e a imagem colorida.
- Mapear as regiões da imagem colorida com as regiões da imagem em tons de cinza.
- Transferir a cor da imagem colorida para a imagem em tons de cinza de acordo com as regiões que foram mapeadas.
- Eliminar a interferência humana no processo.

1.4 Organização do Trabalho

Este texto está dividido em seis capítulos. O Capítulo 2 apresenta conceitos básicos para ajudar no entendimento dos capítulos posteriores. O Capítulo 3 descreve os trabalhos relacionados. O Capítulo 4 descreve a metodologia utilizada, o Capítulo 5 os resultados e o Capítulo 6 apresenta as conclusões.

Capítulo 2

Conceito Básicos

Neste Capítulo são abordados os conceitos básicos sobre redes neurais, representação de imagens digitais e seus espaços de cores.

2.1 Redes Neurais Artificiais

Segundo Nishida [1998] desde que as redes neurais artificiais começaram a surgir muitas definições foram elaboradas com o intuito de esclarecer seus objetivo.

Fausett & Laurene [1994] definem uma rede neural artificial como um sistema de processamento de informação que desempenha função análoga à função das redes neurais biológicas e que as redes neurais artificiais são desenvolvidas a partir de generalizações de modelos matemáticos de cognição e biologia neural.

Nelson et al. [1991] Define que as redes neurais artificiais são técnicas inovadoras de processamento de informações, que tem como objetivo básico, simular em computador o funcionamento do sistema nervoso biológico.

2.2 Imagens Digitais

Uma imagem pode ser definida como uma função bidimensional, $f(x, y)$, em que x e y são coordenadas espaciais (plano), e a amplitude de f em qualquer par de coordenadas (x, y) é chamada de intensidade. Quando (x, y) e os valores de intensidade de f são quantidades finitas e discretas temos uma imagem digital [Gonzalez & Woods, 2001]. A cada ponto $f(x, y)$ dá-se o nome de *pixel*, proveniente do termo *picture element*.

2.2.1 Representação de Imagens

Imagens podem ter origens diversas, podem ser captadas por comprimento de onda de radiação eletromagnética (máquinas fotográficas) ou por ondas sonoras de alta frequência, como, por exemplo o ultrassom. No caso das imagens capturadas por radiação, elas podem ser obtidas por radiações refletidas por objetos translúcidos ou diretamente do emissor da radiação (objetos eminentes). Uma imagem digital consiste na formatação de sua representação de modo que os computadores possam utilizá-la. Para o processamento, a imagem é digitalizada, ou seja, é convertida de contínua (real) para representação discreta (digital). Assim, a imagem pode ter uso computacional, podendo depois ser armazenada na forma de arquivos[Conci et al., 2008].

2.2.2 Imagens Monocromáticas

Imagens Monocromáticas são imagens digitais nas quais cada pixel possui apenas uma banda espectral. As imagens monocromáticas podem ser binárias ou em tons de cinza. Uma imagem binaria é uma imagem monocromática na qual os pixels possuem apenas dois valores, geralmente 0 ou 1. Uma imagem em tons de cinza, é uma imagem monocromática na qual os pixels podem assumir uma faixa de valores intermediários dependendo do número de bits usado para representar a intensidade de cada pixel. Se for usado 1 byte, pode haver 256 tons diferentes, variando do preto ao branco (0 a 255)[Conci et al., 2008].

2.3 Espaço de cores

Essencialmente, um espaço de cores é uma especificação de um sistema de coordenadas e um subespaço dentro desse sistema no qual cada cor é representada por um único ponto. Os principais modelos de cores existentes são o RGB(vermelho, verde, azul) que é amplamente utilizado por dispositivos eletrônicos como monitores, televisores e câmeras digitais, CMY(ciano, magenta, amarelo) utilizado geralmente por dispositivos atuam sobre o papel, como impressoras e copiadoras coloridas, CMYK parecido com CMY mas acrescentando a cor preta, HSI (matiz, saturação, intensidade) amplamente utilizado em processamento de imagens [Gonzalez & Woods, 2001].

2.3.1 Espaço de cores RGB

No espaço de cores RGB, cada cor aparece em seus componentes espectrais primários de vermelho, verde e azul. Esse modelo se baseia em um sistema de coordenadas cartesianas. O subespaço de cores de interesse é o cubo apresentado na Figura 2.1,

no qual os valores RGB primários estão em três vértices, as cores secundárias ciano, magenta e amarelo estão em outros três vértices, o preto está na origem o branco no vértice mais distante da origem. Nesse modelo, os tons de cinza estendem se do preto até o branco ao longo do segmento de reta que une dois pontos. As diferentes cores nesse modelo são pontos no cubo ou dentro dele, e são definidas por vetores que se estendem a partir da origem. Imagens representadas no modelo de cores RGB consistem em três componentes de imagens, uma para cada cor primária. Quando alimentadas em um monitor RGB, essas três imagens se combinam na tela para produzir uma imagem em cores compostas.[Gonzalez & Woods, 2001]

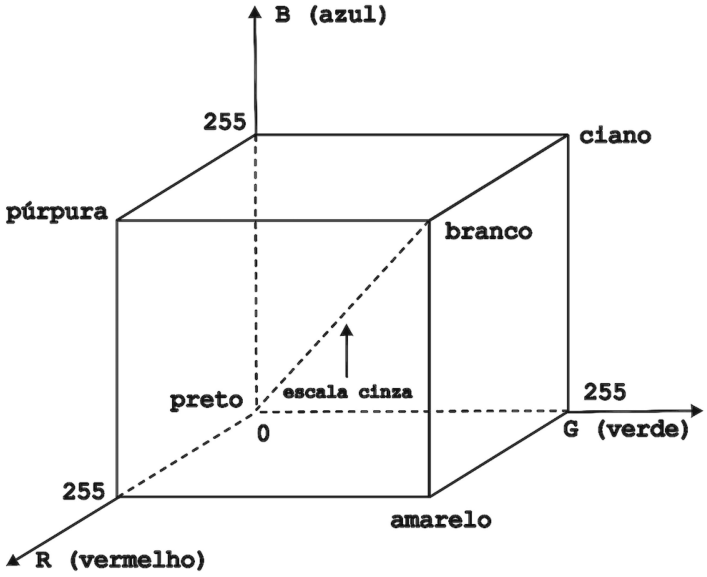


Figura 2.1. Espaço de cores RGB Gonzalez & Woods [2001].

2.3.2 Espaço de cores L$\alpha\beta$.

O espaço de cores $L\alpha\beta$ Figura 2.2 foi proposto por [Ruderman et al., 1998] como resultado de uma análise da resposta do sistema visual humano à cenas naturais. Mais especificamente, foi observado que, a resposta das bandas dos três tipos de cones presentes no olho humano são fortemente correlacionados, se estas respostas fossem convertidas do espaço RGB ao espaço $L\alpha\beta$, esta correlação existente desapareceria [Vieira et al., 2003]. O fato de não haver correlação entre os canais do espaço de cores L$\alpha\beta$ facilita o processo de transferência de cores, pois para isso é preciso apenas transferir os valores presentes nos canais $\alpha\beta$ da imagem referência para a imagem em tons de cinza.

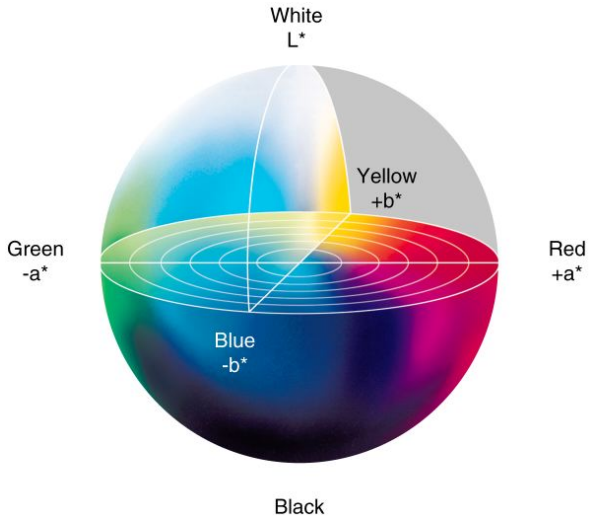


Figura 2.2. Espaço de cores $L\alpha\beta$ Blathur [2013].

2.3.3 Espaço de cores HSV.

Segundo Gonzalez & Woods [2001] o espaço de cores HSV é composto pelos canais de Matiz, Saturação e Valor/Intensidade(Hue, Saturation, Value/Intensity) e é ideal para o desenvolvimento de algoritmo de processamento de imagens com base em descrições de cores que são naturais e intuitivas para os seres humanos. Esse espaço de cores pode ser representando pela forma de um cone como indicado na Figura 2.3.

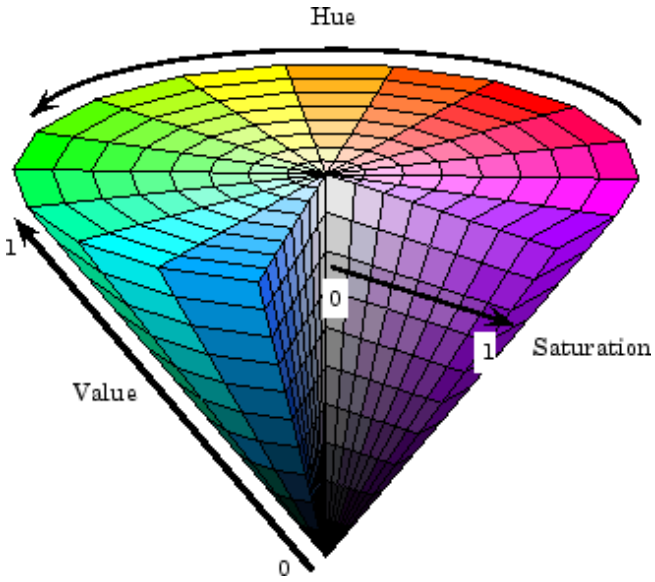


Figura 2.3. Espaço de cores HSV MathWorks [2017].

Capítulo 3

Trabalhos Relacionados

Os trabalhos ligados ao processo de colorir imagens em tons de cinza podem ser divididos em três categorias:

- Coloração manual onde o processo é lento, caro e cansativo mas geralmente produz bons resultados.
- Coloração semi-automática onde a interferência humana tenta ser minimizada.
- Coloração totalmente automática onde não há nenhum tipo de interferência humana no processo

A seguir serão mostrados alguns trabalhos pesquisados dentro das duas últimas categorias: coloração semi-automática e coloração automática.

3.1 Coloração Semi-Automática

A coloração semi-automática de imagens, é a categoria onde é necessário algum tipo de intervenção humana, seja no processo de obter as cores para transferência, ou fornecendo a imagem colorida similar àquela imagem que se deseja colorir, ou durante o processo de colorização.

Levin et al. [2004] propôs uma abordagem onde são utilizados rabiscos para determinar a cor das regiões e a partir desses rabiscos a cor é extrapolada para preencher as regiões, uma outra abordagem possível dentro dessa categoria é proposta por Welsh et al. [2002], onde utiliza-se uma imagem colorida similar como referência para realizar a transferência de cores com base na luminância e no desvio padrão local,(Figura 3.1), no entanto, esse método não funciona bem em cenas onde existe grande variação de luminância entre as regiões da imagem em tons de cinza e as regiões correspondentes

da imagem colorida. Para melhorar os resultados, Welsh et al. [2002] utiliza uma segunda abordagem dentro do seu trabalho(Figura 3.2), onde são feitas demarcações na imagem em tons de cinza e na imagem referência, essas demarcações indicam como a cor vai ser transferida entre as imagens com base na textura das regiões demarcadas.



Figura 3.1. Coloração automática Welsh et al. [2002]



Figura 3.2. Coloração utilizando demarcações Welsh et al. [2002]

3.1.1 Coloração Semi-Automática Avançada

A coloração semi-automática avançada utiliza uma imagem como referência para realizar a transferência de cor e além disso utiliza um método de segmentação para dividir ambas imagens em regiões. Posteriormente, estes grupos são mapeados e a transferência de cor ocorre. Jafar & Sukkar [2010] propôs um método de coloração semi-automática avançada que utiliza o algoritmo de agrupamento *K-means* para separar ambas imagens em um número K de regiões, onde K é fornecido pelo usuário.

As regiões são separadas com base em sua luminância, média, desvio padrão e quatro máscaras de textura. Após isso, é realizado um mapeamento entre os grupos da imagem em tons de cinza e a imagem colorida com base na distância euclidiana.

No entanto, esse mapeamento pode mapear mais de um grupo da imagem colorida com apenas um grupo da imagem em tons de cinza ou vice-versa. Assim, Imran [2011] realizou uma melhoria no método proposto por Jafar & Sukkar [2010] realizando um mapeamento forçado ou seja todo grupo da imagem referência é mapeado em um único grupo da imagem em tons de cinza, e vice-versa, sem que haja repetições, dessa forma nenhum grupo será mapeado em algum outro grupo mais de uma vez e nenhum grupo deixará de ser mapeado.

3.2 Coloração Automática

A coloração automática de imagens, não utiliza interferência humana no processo de coloração, para isso busca uma ou mais imagens de referência em um banco de dados ou treina uma rede neural com uma ou mais imagens referência.

3.2.1 Busca em Banco de Dados

Em Vieira et al. [2007] as imagens coloridas são armazenadas em um banco de dados, cada imagem do banco de dados é indexada utilizando um vetor de características que é extraído de acordo com a luminância da imagem, uma busca é feita para encontrar a imagem que tenha o vetor de características mais similar ao vetor da imagem em tons de cinza, após encontrar a imagem que irá ceder sua cor, o método proposto por Welsh et al. [2002] é utilizando para realizar a transferência de cor.

Em Morimoto et al. [2009] temos uma abordagem parecida com a utilizada por Vieira et al. [2007], no entanto são buscadas 100 imagens de referência, onde apenas as 20 que tem estrutura mais parecidas com a imagem em tons de cinza serão utilizadas, após isso, é utilizado o método proposto por Welsh et al. [2002] para realizar a transferência de cor, gerando varias imagens coloridas, onde o usuário escolhe a imagem que achar que teve o melhor resultado.

Como ambos os métodos citados acima utilizam o método desenvolvido por Welsh et al. [2002], apenas imagens que sejam muito simples tem bons resultados após o processo de coloração, pois para imagens mais complexas é preciso utilizar a abordagem de demarcações descrita por Welsh et al. [2002] para obter bons resultados, o que faria com que ambos os métodos deixassem de ser automáticos.

3.2.2 Redes Neurais

Essa abordagem utiliza aprendizado de máquina, onde uma rede neural é treinada para realizar a coloração de imagens (Figura 3.3). Em Zhang et al. [2016] uma rede neural convolucional (classe de rede neural artificial amplamente aplica em processamento de imagens) foi treinada com um milhão de imagens coloridas, com o objetivo de tentar adivinhar uma cor viável para a imagem em tons de cinza, o método leva em consideração a semântica, e a textura das imagens, pois muitas regiões dão dicas de qual será a cor utilizada. Por exemplo, a grama é tipicamente verde, o céu é tipicamente azul, a joaninha é tipicamente vermelha, é obvio que, ao adivinhar uma cor, nem sempre será utilizada uma cor real, mas o objetivo do trabalho é modelar as dependências estatísticas entre a semântica e as texturas de uma imagem em tons de cinza e sua

versão colorida, para produzir resultados que sejam visualmente bonitos e capazes de enganar os seres humanos.

Para conseguir bons resultados é necessário que a rede neural seja treinada com um número muito grande de imagens, além disso caso apareça alguma imagem que não tem as características presentes nas imagens de treinamento, o algoritmo irá apresentar dificuldades pare realizar o processo de coloração dessa imagem.



Figura 3.3. Entrada, Imagem Colorizada pelo algoritmo, Imagem Original Zhang et al. [2016]

Capítulo 4

Metodologia

Neste capitulo será descrita a metodologia utilizada para realizar o processo de coloração automática de imagens em tons de cinza utilizando uma imagem colorida como referência. A Figura 4.1. ilustra os principais passos desse processo.

Ao receber as imagens de entrada, transformamos a imagem referência que está no espaço de cores RGB para o $L\alpha\beta$ visando facilitar seu processamento e o processo de transferência de cores, após isso, calcula-se as características regionais de ambas as imagens que irão representar cada pixel.

Para realizar o agrupamento dos pixels é necessário informar o número de grupos que serão utilizados pelo algoritmo, para isso detectamos o número de grupos automaticamente analisando o histograma da matiz da imagem colorida.

Feito o agrupamento, é realizado uma mapeamento que indica qual região da imagem colorida irá transferir sua cor para outra região da imagem em tons de cinza, essa transferência ocorre analisando a similaridade entre os pixels da região da imagem colorida com os pixels da imagem em tons de cinza.

4.1 Base de Imagens

O primeiro passo deste trabalho foi construir uma base de imagens coloridas e suas versões em tons de cinza.

4.2 Imagens de Entrada

O método desenvolvido neste trabalho, utiliza duas imagens como entrada, uma imagem em tons de cinza, e uma imagem colorida similar a imagem em tons de cinza, que irá transferir suas características cromáticas.

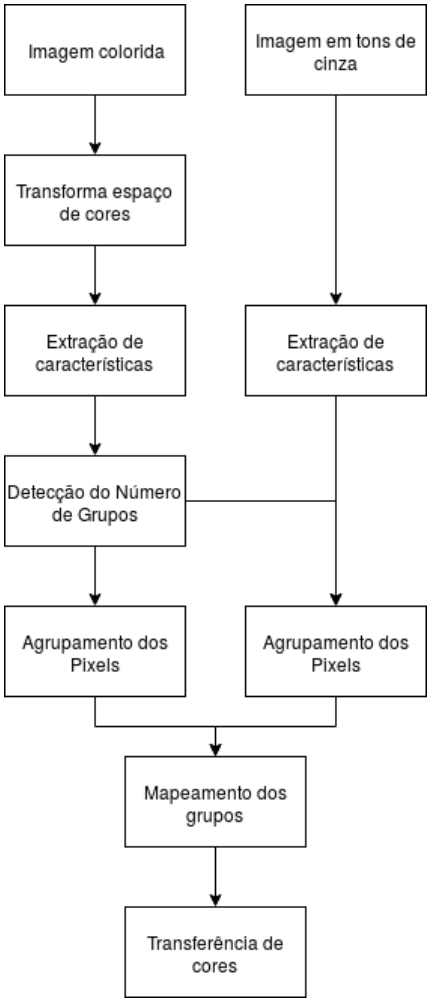


Figura 4.1. Esquema da metodologia utilizada

4.3 Mudança de Espaço de Cores

Um dos primeiros passos dentro do trabalho é transformar a imagem colorida que está no espaço de cores RGB para o espaço de cores L$\alpha\beta$, pois, nesse espaço podemos manipular a Luminância em um único canal separado,o que será muito útil pois todos os cálculos de características serão calculados com base na luminância das imagens. Além disso a transferência de cores é facilitada, pois observando a similaridade entre os pixels e o mapeamento realizado, é possível apenas passar os canais $\alpha\beta$ da imagem referência, para a imagem em tons de cinza, para realizar a coloração.

4.4 Extração de Características

Definir quais características serão utilizadas para descrever os pixels das imagens é uma das etapas mais importantes deste trabalho, pois através dessas características é

possível determinar a similaridade entre os pixels e, portanto, definir grupos(regiões) com os pixels mais similares. Cada uma das características será calculada localmente, utilizando a vizinhança dos pixels para descreve-los, serão utilizadas combinações dessas características para descrever cada pixel, foram realizados testes com as seguintes características :

- Luminância
- Desvio Padrão
- Entropia
- Variância
- Suavidade
- Uniformidade
- *Local Binary Pattern* (LBP)
- 3º Momento
- 5º Momento
- Máscara de Sobel.

4.4.1 Variância e Desvio Padrão

A variância de uma imagem pode ser calculada como o valor do desvio médio dos níveis de cinza NC_i da imagem em relação ao nível de cinza médio NCM, já o desvio padrão é a raiz quadrada da variância e informa sobre a maior homogeneidade ou heterogeneidade de uma imagem. Segundo Press et al. [2007], a Eq. 4.1 pode ser utilizada para calcular a variância. Ambas, variância e desvio padrão, podem ser calculadas tomando todos os pixels da imagem ou olhando para a vizinhança em torno de cada pixel.

$$Var_I = \frac{\sum_{i=1}^{N}(NC_i - NCM)^2}{N-1} \tag{4.1}$$

4.4.2 Entropia

Uma das formas de se estimar a textura presente em imagens é através do cálculo da entropia. Esse cálculo pode ser utilizado para medir a quantidade de informação presente em imagens.

A entropia de uma imagem pode ser obtida a partir das intensidades dos níveis de cinza em uma imagem. Estas intensidades estão presentes no histograma de luminância, $P(i)$, da própria imagem. Assim, se considerarmos que o histograma $P(i)$ representa a probabilidade do nível de luminância i ocorrer na imagem, segundo Gonzalez & Woods [2001], a Eq. 4.3 pode ser utilizada para expressar a entropia $E(I)$ de uma imagem I com N níveis de luminância (ou níveis de cinza):

$$E_I = -\sum_{i=0}^{N-1} P(i)(\log_2 P(i)) \tag{4.2}$$

Como há a necessidade de obter a entropia em cada pixel da imagem de entrada, pode-se levar em consideração uma pequena região ao redor de cada pixel de interesse para o cálculo da entropia local.

4.4.3 Local Binary Pattern

Local Binary Pattern (LBP) é um simples e eficiente operador que descreve localmente os padrões de textura em uma dada vizinhança de uma imagem.Ojala et al. [1995] A vizinhança 3x3 é limitada pelo elemento central, em seguida é atribuído o número 1 para os elementos maiores ou iguais ao elemento central, e 0 para o restante, formando assim um padrão binário. o valor inteiro desse padrão binário na base decimal representa o valor da textura no elemento central. A Figura 4.2. ilustra esse cálculo, e tem como resultado o valor 169 para o elemento central.

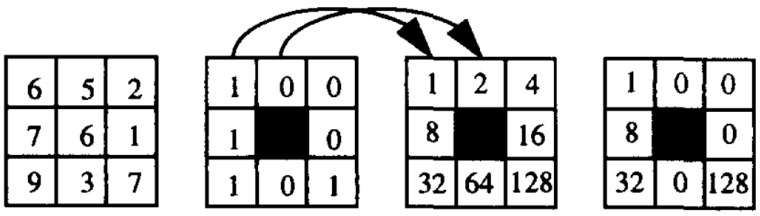


Figura 4.2. cálculo LBP Ojala et al. [1995]

4.4.4 Momentos estatísticos

Segundo Gonzalez & Woods [2001] uma das abordagens mais simples para descrever textura é usar momentos estatísticos do histograma de intensidade (lista representando o número de ocorrências de cada nível de intensidade) de uma imagem. Seja N o número de níveis distintos de intensidade, *P(i)* a probabilidade de ocorrência do nível

de intensidade i e m o nível de intensidade médio, o n-ésimo momento pode ser dado pela Eq 4.3.

$$U_n(I) = -\sum_{i=0}^{N-1} (P(i) - m)^n P(i) \tag{4.3}$$

Ainda, segundo Gonzalez & Woods [2001], o segundo momento (Variância) é importante na descrição de texturas, fornece uma medida de contraste de intensidade que pode ser usada estabelecer descritores de suavidade relativa, como por exemplo Eq 4.4.

$$R(I) = 1 - \frac{1}{1 + \sigma^2(i)} \tag{4.4}$$

Além disso temos o terceiro momento que é uma medida de assimetria do histograma e o quinto momento que não está tão relacionado com o histograma mas sim relacionada com a textura. Existem ainda, outras medidas adicionais de textura baseadas em histograma, como por exemplo, a uniformidade que é dada pela equação Eq 4.5.

$$U(I) = \sum_{i=0}^{N-1} P(i)^2 * i \tag{4.5}$$

4.4.5 Máscara de Sobel para identificar bordas

Segundo Gonzalez & Woods [2001] a detecção de bordas é o método usado mais frequentemente para segmentar as imagens com base nas variações abruptas de intensidade. Para esse trabalho utilizamos as máscaras de Sobel para detectar bordas através das máscaras abaixo.

$$X = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix}$$

$$Y = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}$$

4.4.6 Melhor combinação de características

Para realizar a segmentação das imagens, os pixels foram agrupados de acordo com sua similaridade formando regiões, portanto escolher quais características irão representar os pixels das imagens é essencial para o bom funcionamento do método proposto.

A escolha da melhor combinação de características foi feita a partir de testes, onde o processo de coloração foi aplicado a um conjunto de imagens, utilizando combinações das características citadas na seção anterior, essas combinações foram escolhidas em grupos 3, 4 ou 5 características.

Após obter o resultado da coloração das imagens de teste utilizando cada uma das combinações de características, foi escolhida a combinação que proporcionou melhor resultado visual após o processo de coloração.

4.4.7 Métricas de Similaridade

Os pixels serão agrupados em regiões de acordo com suas similaridades, portanto definir métricas de similaridade entre eles é um passo importante para obter uma boa coloração para as imagens. Foram realizados testes utilizando três métricas diferentes, a distância euclidiana, City Block e a Similaridade dos cossenos.

- Distância Euclidiana

  A distância euclidiana mede a similaridade entre dois pixels e através da Eq 4.6, Cha [2007] onde R_i indica a característica i do pixel pertencente a imagem referência e C_i a característica i do pixel pertencente a imagem em tons de cinza, d indica o número de características que descrevem o pixel.

- City Block

  A distância city block é definida pela Eq 4.7 Cha [2007], onde R_i, C_i, e d têm os mesmos valores citados anteriormente.

- Similaridade dos cossenos

  A Similaridade dos cossenos é definida pela Eq 4.8 Cha [2007], onde o cosseno do ângulo entre os vetores de características dos pixels indica a similaridades entre eles.

A escolha da melhor métrica de similaridade foi feita através de uma análise subjetiva dos testes, onde aquela que proporcionasse resultados visualmente melhores durante a coloração das imagens seria a escolhida. A distância euclidiana obteve melhores resultados, portanto foi a escolhida.

$$S = \sqrt{\sum_{i=1}^{d} |R_i - C_i|^2} \tag{4.6}$$

$$S = \sum_{i=1}^{d} |R_i - C_i| \tag{4.7}$$

$$S_c = \frac{\sum_{i=1}^{d} R_i C_i}{\sqrt{\sum_{i=1}^{d} R_i^2}\sqrt{\sum_{i=1}^{d} C_i^2}} \tag{4.8}$$

4.5 Detecção do Número de Grupos

Durante a execução do projeto foram testados dois métodos para definir o número de grupos(numero de regiões em que as imagens será dividida) automaticamente, o Elbow Method e análise do histograma do canal H do espaço de cores HSV.

4.5.1 Elbow Method (Método do Cotovelo)

O Elbow Method acrescenta iterativamente o número de grupos utilizados para segmentar a imagem de forma que, em um dado momento, acrescentar o número de grupos não vai mais trazer um bom ganho de informações, isso é onde fica o cotovelo, e também o número de grupos que pode-se utilizar [Tibshirani et al., 2000]. O Elbow Method foi testado como forma de encontrar automaticamente o número de grupos da imagem, no entanto por ter um auto custo foi descartado.

4.5.2 HSV (Hue, saturation, value)

Segundo Gonzalez & Woods [2001] o matiz (Canal H do HSV) é um atributo associado ao comprimento de onda dominante em uma mistura de ondas de luz, assim o matiz representa a cor dominante percebida por um observador. Portanto para identificar o número de cores dominantes em uma imagem e consequentemente o número de grupos que serão utilizados para agrupar os pixels, transformamos a imagem referência para o espaço de cores HSV e utilizamos o histograma do canal H, suavizado através do savitsky-golay filter Schafer [2011], para identificar os picos e portanto o número de grupos.

4.6 Normalização dos dados

Cada tipo de característica obtida, tem valores mínimos e máximos diferentes portanto elas foram normalizadas dentro do intervalo [0,1] para que durante o processo de agrupamento e mapeamento, cada tipo de característica tivesse o mesmo ‘peso’, onde o maior valor de luminância encontrado seria definido como 1, o maior nível de entropia

encontrado seria definido como 1, e o maior desvio padrão encontrado também seria definido como 1.

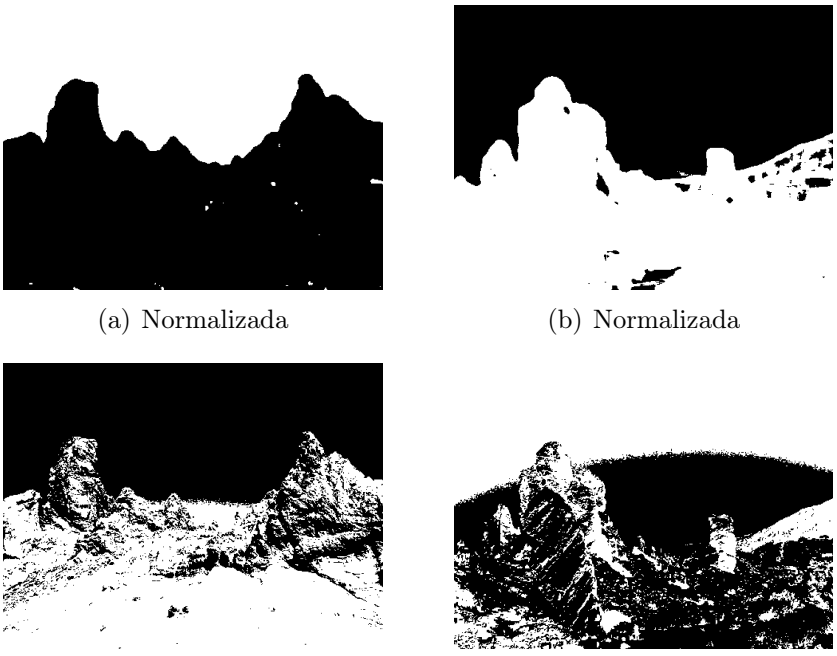
Portanto, para cada matriz de características obtida foi aplicada a Eq 4.9 definida em Stephanie [2015], onde i representa o índice de luminância, entropia ou desvio padrão atual, e Min e Max seus respectivos máximos e mínimos. Realizar esse tipo de normalização trouxe segmentações melhores, como mostrado na Figura 4.4 que representa a segmentação em 2 grupos das imagens disponíveis na Figura 4.3.

$$N(i) = \frac{i - Min}{Max - Min} \tag{4.9}$$



(a) Imagem tons de cinza (b) Imagem referência

Figura 4.3. Imagem referência e Imagem em tons de cinza



(a) Normalizada (b) Normalizada

(c) Não normalizada (d) Não normalizada

Figura 4.4. Comparação da segmentação das imagens, normalizadas e não normalizadas

4.7 Agrupamento dos Pixels utilizando o K-Means

K-means é um algoritmo de aprendizado não supervisionado [Hartigan & Wong, 1979; Kanungo et al., 2002; Jain, 2010; Imran, 2011] utilizado para realizar agrupamento de dados em k grupos, neste trabalho, ele foi utilizado para agrupar os pixels de cada imagem em k diferentes grupos. O algoritmo segue os seguintes passos :

1. Defina K como sendo o numero de grupos
2. Dê posições aleatórias para cada um desses grupos, cada uma dessas posições é chamada de centroide.
3. Classifique os dados de acordo com a distância euclidiana até o centroide mais próximo.
4. Calcule a média dos pontos pertencentes à cada centroide para definir a nova posição do centroide.
5. Repita os itens 3 e 4 até que os centroides estabilizem suas posições.

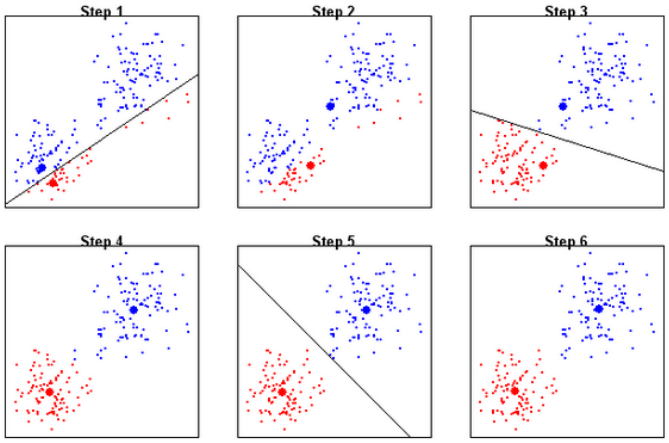


Figura 4.5. Funcionamento do K-Means Towers [2013].

Para dividir as duas imagens em grupos utilizamos as características definidas anteriormente, passamos para o K-means uma matriz de tamanho 3xNP(Número de Pixels) para cada imagem, onde cada linha representa um pixel e cada coluna representa uma característica. Ao final da execução do K-means, temos como retorno um label para cada pixel indicando a qual grupo ele pertence, e um vetor indicando a posição dos centroides de cada grupo.

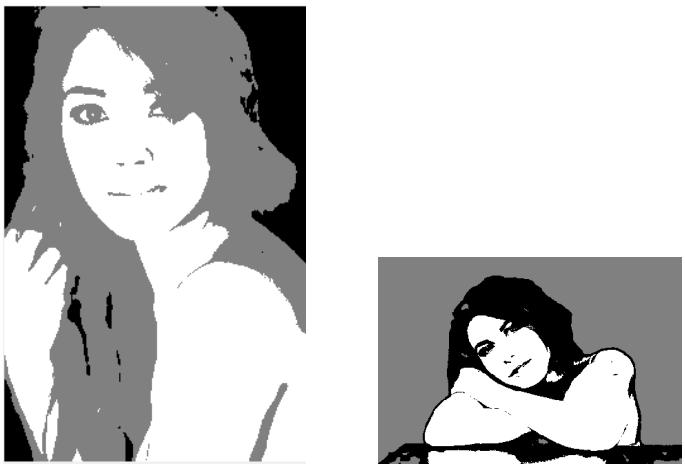
4.8 Mapeamento dos grupos

O mapeamento entre os grupos é feito utilizando os centroides fornecidos pelo K-Means. Seja G uma lista com a posição dos centroides da imagem em tons de cinza e C a lista com os centroides da imagem colorida, calcula-se a distancia de cada centroide pertencente a G em relação aos centroides de C, então escolha um centroide g_i e o mapeie em um centroide c_k no qual a distancia entre os dois é mínima, em seguida retire os g_i de G e c_k de C, esse processo é repetido até que todos os centroides estejam mapeados e as listas fiquem vazias. O exemplo a seguir mostra o mapeamento realizado para a Figura 4.6, e a Figura 4.7 mostra a segmentação obtida utilizando 3 grupos.



(a) Imagem referência (b) Imagem tons de cinza

Figura 4.6. Imagem referência e imagem em tons de cinza



(a) Segmentação imagem referência (b) Segmentação imagem tons de cinza

Figura 4.7. Segmentação da Imagem referência e da imagem em tons de cinza

A Tabela 4.8 mostra a posição dos centroides obtidos pelo K-means para a imagem colorida e a Tabela 4.8 mostra os centroides da imagem em tons de cinza. Utilizamos essas tabelas para realizar o cálculo da distância entre cada um dos centroides e obtemos a Tabela 4.8, que nos dá o seguinte mapeamento :

- Grupo 1 Imagem Referência mapeado em Grupo 2 Imagem tons de cinza
- Grupo 2 Imagem Referência mapeado em Grupo 1 Imagem tons de cinza.
- Grupo 3 Imagem Referência mapeado em Grupo 3 Imagem tons de cinza.

Centroides	Luminância	Desvio Padrão	Entropia
Cor 1	0,7443	0,0863	0,7819
Cor 2	0,0330	0,0096	0,3344
Cor 3	0,1824	0,1287	0,8183

Tabela 4.1. Posição dos centroides da imagem colorida.

Centroides	Luminância	Desvio Padrão	Entropia
Cinza 1	0,0889	0,0066	0,1358
Cinza 2	0,7716	0,0915	0,7404
Cinza 3	0,2257	0,1571	0,7597

Tabela 4.2. Posição dos centroides da imagem cinza.

Distâncias	Cinza1	Cinza2	Cinza3
Cor1	0,9237	0,2063	0,6996
Cor2	0,0499	0,8468	0,5954
Cor3	0,5238	0,4896	0,07819

Tabela 4.3. Distância entre os centroides da imagem colorida em relação a imagem em tons de cinza.

4.9 Transferência de Cores

Uma vez definido o mapeamento entre os grupos, cada pixel P_i da imagem em tons de cinza que pertence a um grupo **I** vai receber os valores dos canais α e β de um pixel P_k pertencente ao grupo **K** correspondente na imagem colorida, a escolha do pixel ocorre calculando a distancia entre P_i e cada pixel P_k do grupo **K**, aquele que tiver a menor distância em relação ao pixel P_i irá transferir seus valores α e β para P_i.

Capítulo 5

Resultados e Discussões

Neste capítulo serão discutidos os testes realizados e os resultados obtidos. Os testes foram feitos em um notebook Intel Core i3 6ª geração, 4GB de memória RAM e sistema operacional Ubuntu 16.04 LTS 64 bits.

5.1 Conjunto de Características

A escolha de qual conjunto de características regionais iriam representar os pixels das imagens foi feita através de testes com diferentes combinações dos conjuntos de características. Para cada conjunto, os pixels foram agrupados de acordo com a similaridade entre eles, dessa forma ao variar o conjunto de características que representam cada pixel, regiões diferentes surgem durante o agrupamento. Ao fim dos testes o conjunto escolhido foi :

- Luminância.
- Desvio Padrão.
- Entropia.

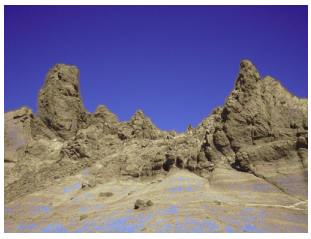
A Figura 5.1 apresenta uma comparação entre alguns dos conjuntos de características utilizados para colorir as imagens, isso mostra como a escolha dessas características podem afetar o resultado do processo de coloração.



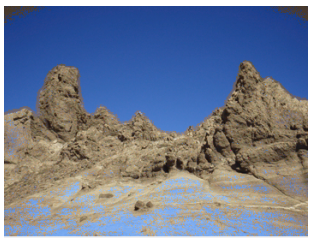
(a) Imagem referência



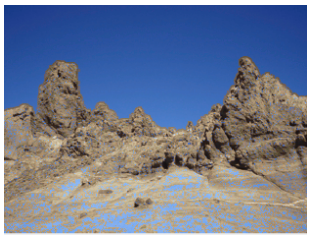
(b) Imagem em tons de Cinza



(c) Luminância, Entropia, Desvio Padrão



(d) Luminância, Entropia, LBP



(e) Luminância, Uniformidade, Suavidade

Figura 5.1. Comparação entre conjuntos de características

5.2 Métricas de Similaridade

A escolha de qual métrica de similaridade seria utilizada durante o método de coloração de imagens foi feita através de testes, onde aquela com melhores resultados nos testes propostos foi a escolhida.

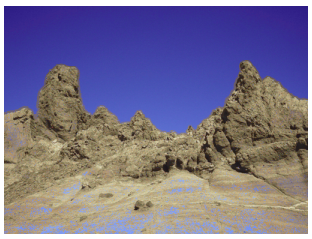
A partir dos exemplos exibidos nas Figuras 5.2 e 5.3 é possível ver que a distâncias euclidiana obteve melhores resultados na coloração quando comparada com a CityBlock e a Similaridade dos Cossenos.



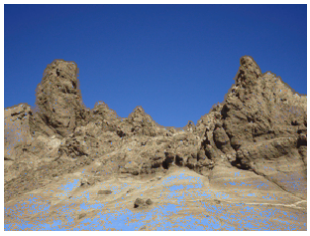
(a) Imagem referência



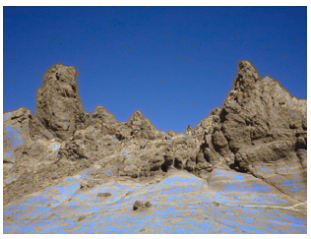
(b) Imagem em tons de Cinza



(c) Distância euclidiana



(d) City Block



(e) Similaridade dos Cossenos

Figura 5.2. Comparação entre métricas de similaridade



(a) Imagem referência



(b) Imagem em tons de Cinza



(c) Distância euclidiana



(d) City Block



(e) Similaridade dos Cossenos

Figura 5.3. Comparação entre métricas de similaridade

5.3 Método Desenvolvido vs Welsh et al.

Essa seção irá fazer um comparativo entre os resultados obtidos pelo método desenvolvido neste trabalho com os resultados obtidos pelo método proposto por Welsh et al. [2002], que é um dos principais métodos existentes na literatura.

5.3.1 Auto-Coloração

Os primeiros testes foram realizados utilizando como referência a própria versão colorida da imagem em tons de cinza, dessa forma temos a situação ideal para realizar a transferência de cores. As imagens a seguir mostram os resultados obtidos pela auto-coloração. É possível ver que em situação ideal os dois métodos funcionaram muito bem, colorindo quase que perfeitamente as imagens em tons de cinza.



(a) Imagem referência



(b) Imagem tons de cinza



(c) Resultado



(d) Resultado Welsh

Figura 5.4. Coloração bem-sucedida



(a) Imagem referência



(b) Imagem tons de cinza



(c) Resultado



(d) Resultado Welsh

Figura 5.5. Coloração bem-sucedida



(a) Imagem referência



(b) Imagem tons de cinza



(c) Resultado



(d) Resultado Welsh

Figura 5.6. Coloração bem-sucedida



(a) Imagem referência



(b) Imagem tons de cinza



(c) Resultado



(d) Resultado Welsh

Figura 5.7. Coloração bem-sucedida



(a) Imagem referência



(b) Imagem tons de cinza



(c) Resultado



(d) Resultado Welsh

Figura 5.8. Coloração bem-sucedida



(a) Imagem referência



(b) Imagem tons de cinza



(c) Resultado



(d) Resultado Welsh

Figura 5.9. Coloração bem-sucedida

5.3.2 Erros

Para definir a eficiência da auto-coloração, foi calculada a diferença absoluta pixel a pixel entre as imagens referência originais e as imagens que foram auto-colorizadas, essa diferença pixel a pixel nos mostra o erro, entre a imagem colorizada e a imagem real, portanto, quanto mais próximo de zero for essa diferença, melhor será o resultado obtido pelo algoritmo. As tabelas a seguir mostram uma comparação feita entre os dois métodos em relação a média e desvio padrão do erro calculado para cada uma das bandas do espaço de cores RGB das imagens que foram utilizadas para testar o método de auto-coloração.

De acordo com as tabelas abaixo, em uma situação ideal ou seja quando a coloração da imagens em tons de cinza é feita utilizando sua própria versão colorida, o método desenvolvido neste trabalho, tem um melhor resultado quando comparado com o proposto por Welsh et al. [2002], pois é possível ver que para todas as imagens o erro médio e o desvio padrão estão mais próximas de zero, o que indica um erro menor.

Erros	Média	Desvio Padrão	vs	Média(Welsh)	Desvio Padrão(Welsh)
R	**0.3040**	**0.4695**		2.5174	2.7938
G	**0.1173**	**0.3218**		2.4514	2.6515
B	**0.3138**	**0.5465**		2.5414	2.8217

Tabela 5.1. Erros relacionados a Figura 5.4

Erros	Média	Desvio Padrão	vs	Média(Welsh)	Desvio Padrão(Welsh)
R	**0.1516**	**0.3600**		2.7088	3.4676
G	**0.0597**	**0.2370**		2.5460	3.1278
B	**0.4369**	**0.4980**		2.5012	3.0133

Tabela 5.2. Erros relacionados a Figura 5.5

Erros	Média	Desvio Padrão	vs	Média(Welsh)	Desvio Padrão(Welsh)
R	**0.2427**	**0.4484**		3.8020	2.3532
G	**0.0820**	**0.2750**		3.6009	2.1861
B	**0.4407**	**0.5125**		3.7348	2.0826

Tabela 5.3. Erros relacionados a Figura 5.6

Erros	Média	Desvio Padrão	vs	Média(Welsh)	Desvio Padrão(Welsh)
R	**0.4192**	**0.5033**		6.4876	3.2995
G	**0.1186**	**0.3233**		6.4128	3.1430
B	**0.4239**	**0.5033**		6.4100	3.1847

Tabela 5.4. Erros relacionados a Figura 5.7

Erros	Média	Desvio Padrão	vs	Média(Welsh)	Desvio Padrão(Welsh)
R	**0.6603**	**0.7586**		9.5492	6.4864
G	**0.1163**	**0.3206**		8.8751	4.8351
B	**0.4316**	**0.5015**		9.3426	5.4911

Tabela 5.5. Erros relacionados a Figura 5.8

Erros	Média	Desvio Padrão	vs	Média(Welsh)	Desvio Padrão(Welsh)
R	**0.7731**	**0.8139**		15.7299	11.1757
G	**0.1381**	**0.3450**		9.8335	4.1201
B	**0.4532**	**0.4987**		10.5967	5.1018

Tabela 5.6. Erros relacionados a Figura 5.9

5.3.3 Transferência de Cores

Abaixo podem ser vistos os resultados obtidos pelo método desenvolvido neste trabalho, em comparação com os obtidos pelo método proposto por Welsh et al. [2002], como a análise de qualidade da coloração das imagens em tons de cinza é subjetiva, um formulário foi disponibilizado via Rede Social, para votação, onde os usuários dessa Rede Social iriam escolher qual a melhor coloração. Foram recebidos 52 votos, os resultados podem ser vistos na Tabela 5.7.

A Tabela 5.7 nos mostra que o método proposto foi mais bem avaliado em quatro das seis imagens que foram disponibilizadas para votação. Mostrando que é capaz de realizar o processo de coloração de forma mais eficiente do que o método proposto por Welsh et al. [2002]. Um exemplo claro disso é a Figura 5.12 onde o método proposto conseguiu colorir cada região da imagem separadamente obtendo um bom resultado, enquanto o método desenvolvido por Welsh et al. [2002] falha, pois aplica praticamente a mesma tonalidade de cor em toda a imagem.

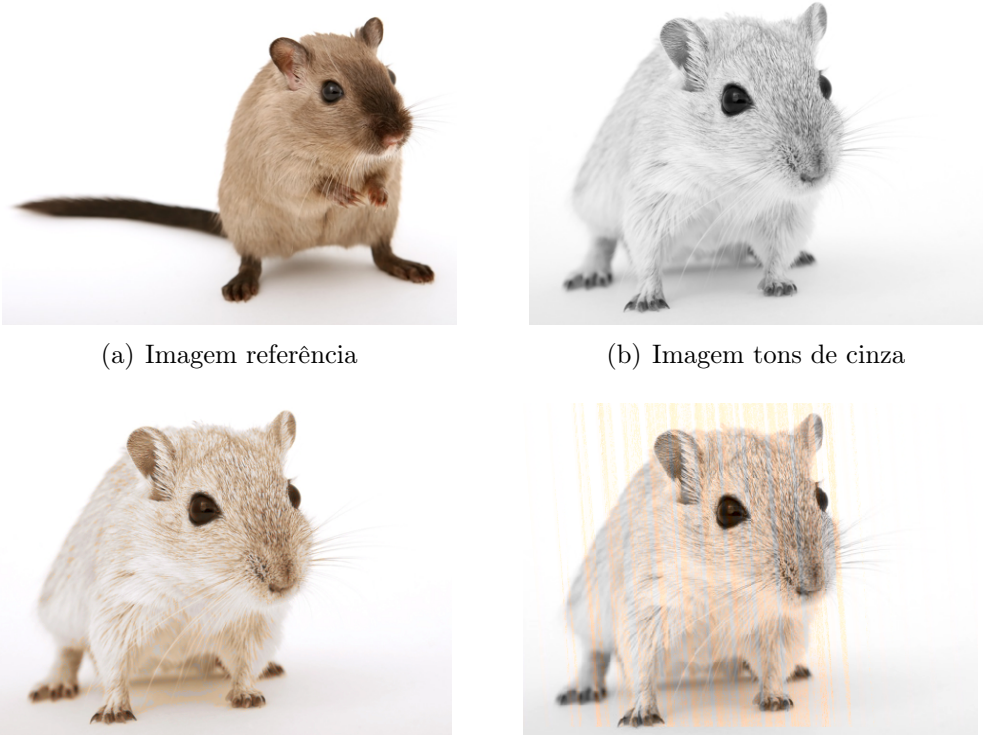
Ambos os métodos obtiveram falhas, como é possível ver na Figura 5.14, isso ocorreu pois as regiões da imagem em tons de cinza tem texturas similares e níveis de cinza muito próximos, o que acaba dificultando o processo de segmentação (para o método proposto) e o processo de coloração(para ambos os métodos).

Além disso para realizar a transferência de cores o método proposto realiza um número menor de operações, pois para cada pixel da imagem em tons de cinza é necessário

buscar o seu correspondente (pixel mais similar que irá transferir suas características cromáticas) apenas no grupo em que se está mapeado da imagem colorida, enquanto no método proposto por Welsh et al. [2002] o pixel que irá fornecer suas características cromáticas é encontrado buscando toda a imagem referência.

Avaliação Subjetiva	Fig 5.10	Fig 5.11	Fig 5.12	Fig 5.13	Fig 5.14	Fig 5.15
Método Proposto	**96,2**%	38,5%	**88,5**%	**78,8**%	45,1%	**53,8**%
Welsh et al.	3,8%	**61,5**%	11,5%	21,2%	**54,9**%	46,2%

Tabela 5.7. Porcentagem de votos recebidos durante a avaliação subjetiva.



(a) Imagem referência

(b) Imagem tons de cinza

(c) Resultado

(d) Resultado Welsh et al.

Figura 5.10. Coloração bem-sucedida



(a) Imagem referência



(b) Imagem tons de cinza



(c) Resultado



(d) Resultado Welsh et al.

Figura 5.11. Coloração bem-sucedida



(a) Imagem referência



(b) Imagem tons de cinza



(c) Resultado



(d) Resultado Welsh et al.

Figura 5.12. Coloração bem-sucedida



(a) Imagem referência



(b) Imagem tons de cinza



(c) Resultado Método Proposto



(d) Resultado Welsh et al.

Figura 5.13. Coloração bem-sucedida



(a) Imagem referência



(b) Imagem tons de cinza



(c) Resultado



(d) Resultado Welsh et al.

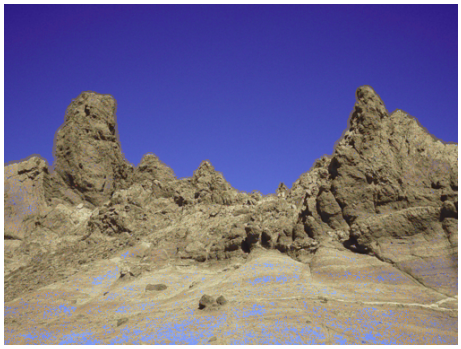
Figura 5.14. Coloração com falhas



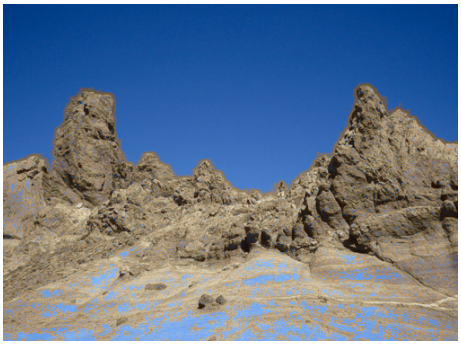
(a) Imagem referência



(b) Imagem tons de cinza



(c) Resultado Método Proposto



(d) Resultado Welsh et al.

Figura 5.15. Coloração com falhas

Capítulo 6

Conclusões

O método desenvolvido neste trabalho, mostrou ser capaz de realizar a coloração de imagens em tons de cinza de forma semi-automática, pois ainda é necessário fornecer uma imagem colorida como referência, portanto ele ainda é classificado como um método semi-automático avançado.

O algoritmo funciona bem em imagens onde suas regiões tem níveis de luminância bem distintos, pois todas características utilizadas são baseadas na luminância, caso regiões diferentes tenham níveis de luminância parecidos, possivelmente serão identificadas como um único grupo o que atrapalha o processo de coloração.

Como trabalhos futuros propõe-se a criação de uma grande base de dados de imagens coloridas e a utilização ou desenvolvimento de um método de busca em banco de dados para buscar imagens coloridas similares à imagem em tons de cinza em conjunto com o método desenvolvido neste trabalho, pois dessa forma seria possível executar a coloração de forma totalmente automática.

Referências Bibliográficas

Arbelot, B.; Vergne, R.; Hurtut, T. & Thollot, J. (2015). Color transfer and colorization based on textural properties. info:eu-repo/semantics/report; reports, HAL CCSD.

Blathur, S. (2013). Lab color space. http://sheriffblathur.blogspot.com.br/2013/07/cie-lab-color-space.html. Acesso em: 24/08/2017.

Cha, S.-H. (2007). Comprehensive survey on distance/similarity measures between probability density functions. *INTERNATIONAL JOURNAL OF MATHEMATICAL MODELS AND METHODS IN APPLIED SCIENCES*, 1(4):300–307.

Chris (2008). Casablanca. http://film-blender.blogspot.com.br/2008/12/blasphemy.html. Acesso em: 10/08/2017.

Conci, A.; Azevedo, E. & Leta, F. R. (2008). *Computação Gráfica Teoria e Prática*. Elsevier Editora. MIT Electrical Engineering and Computer Science Series.

Edgerton, G. R. (2000). The germans wore gray, you wore blue. Journal of Popular Film and Television.

Fausett & Laurene (1994). Fundamentals of neural networks architectures, algorithms, and applications. *Florida Institute of Technology*.

Gonzalez, R. C. & Wintz. (1987). *Digital Image Processing*. Addison-Wesley Longman Publishing Co., Inc.

Gonzalez, R. C. & Woods, R. E. (2001). *Digital Image Processing*. Addison-Wesley Longman Publishing Co., Inc., Boston, MA, USA, 2nd edição.

Hartigan, J. A. & Wong, M. A. (1979). Algorithm as 136: A k-means clustering algorithm. *Journal of the Royal Statistical Society. Series C (Applied Statistics)*, 28(1):100–108.

Imran, M. (2011). Colorizing grey scale images. Master's thesis, Dalarna University, Computer Engineering.

Jafar, I. F. & Sukkar, G. M. A. (2010). A novel coloring framework for grayscale images.

Jain, A. K. (2010). Data clustering: 50 years beyond k-means. *Pattern recognition letters*, 31(8):651–666.

Kanungo, T.; Mount, D. M.; Netanyahu, N. S.; Piatko, C. D.; Silverman, R. & Wu, A. Y. (2002). An efficient k-means clustering algorithm: Analysis and implementation. *IEEE transactions on pattern analysis and machine intelligence*, 24(7):881–892.

Levin, A.; Lischinski, D. & Weiss, Y. (2004). Colorization using optimization. *ACM Trans. Graph*, 23(3):689–694.

MathWorks (2017). Convert from hsv to rgb color space. https://www.mathworks.com/help/images/convert-from-hsv-to-rgb-color-space.html. Acesso em: 29/01/2018.

Morimoto, Y.; Taguchi, Y. & Naemura, T. (2009). Automatic colorization of grayscale images using multiple images on the web. *SIGGRAPH*.

Nelson; Marilyn & Illingworth (1991). A pratical guide to neural nets. *Addison-Wesley Publishing Company, Inc. USA*.

Nishida, W. (1998). Uma rede neural artificial para classificaÇÃo de imagens multiespectrais de sensoriamento remoto. *Uninfersidade Federal de Santa Catarina*.

Ojala, T.; Pietikainen, M. & Harwood, D. (1995). A comparative study of texture measures with classification based on feature distributions.

Press, W. H.; Teukolsky, S. A.; Vetterling, W. T. & Flannery, B. P. (2007). *Numerical Recipes The art of Scientific Computing*. Cambridge University.

Que, Z. (2013). Old vs new restoration of historic pictures. http://www.designbolts.com/2013/08/21/old-vs-new-restoration-of-historic-pictures/. Acesso em: 10/08/2017.

Reinhard, E.; Ashikhmin, M.; Gooch, B. & Shirley, P. (2001). Color transfer between images. *IEEE Computer Graphics and Applications*, 21(5):34–41.

Ruderman, D. L.; Cronin, T. W. & Chiao, C.-C. (1998). Statistics of cone responses to natural images: Implications for visual coding. *Journal of the Optical Society of America A*, 15:2036–2045.

Schafer, R. W. (2011). What is a savitzky-golay filter? *EEE SIGNAL PROCESSING MAGAZINE*, pp. 111 – 117.

Silva, E. D. C.; da Silva Benedito, C. C.; de Barros, W. F. & Santos, L. I. (2016). Coloração artificial de imagens em tons de cinza utilizando uma imagem de referência. In *XIX ENMC - Encontro Nacional de Modelagem Computacional*, João Pessoa-PB.

Stephanie (2015). Normalized data / normalization. http://www.statisticshowto.com/normalized/. Acesso em: 29/01/2018.

Tibshirani, R.; Walther, G. & Hastie, T. (2000). Estimating the number of clusters in a data set via gap statistic. Stanford University.

Towers, S. (2013). K-means clustering. http://sherrytowers.com/2013/10/24/k-means-clustering/. Acesso em: 22/08/2016.

Vieira, L. F. M.; do Nascimento, E. R.; Fernandes, F. A.; Carceroni, R. L.; Vilela, R. D. & de Albuquerque Araujo, A. (2007). Fully automatic coloring of grayscale images. *Image and Vision Computing*, 25(1):50–60.

Vieira, L. F. M.; Vilela, R. D.; do Nascimento, E. R.; Jr., F. A. F.; Carceroni, R. L. & de Albuquerque Araújo, A. (2003). Automatically choosing source color images for coloring grayscale images. In *SIBGRAPI*, pp. 151–158. IEEE Computer Society.

Welsh, T.; Ashikhmin, M. & Mueller, K. (2002). Transferring color to greyscale images. In Hughes, J., editor, *SIGGRAPH 2002 Conference Proceedings*, Annual Conference Series, pp. 277–280. ACM Press/ACM SIGGRAPH.

Zhang, R.; Isola, P. & Efros, A. A. (2016). Colorful image colorization.